

En esta sección se presentan los resultados obtenidos en el proyecto, organizados por las siguientes fases, el desempeño del agente PPO durante el entrenamiento, la comparación de las proyecciones del espacio de estados antes y después del entrenamiento, las métricas de calidad de las proyecciones UMAP, y el análisis de especialización de la política aprendida.

A. Desempeño del agente PPO

El entrenamiento del agente PPO se completó en 1.000.000 de pasos, con un total de 6498 episodios en un tiempo aproximado de 38,3 minutos utilizando una GPU T4. La curva de aprendizaje, representada en la Figura 3, muestra 3 fases que se pueden distinguir.

Durante la fase inicial de exploración entre los episodios 0-500, el agente actúa sin una estrategia, por lo que la media móvil de recompensa es alrededor de 4 puntos. En los episodios siguientes, entre 500-3000, el agente comienza a identificar qué acciones resultan más ventajosas en cada situación, lo que se puede ver en el aumento de la recompensa obtenida, pues alcanza aproximadamente los 16 puntos. Por último, a partir del episodio 3000 y hasta el final del entrenamiento, las mejoras se vuelven menores y la recompensa se mantiene en un rango de 17 a 19 puntos, el cual es un comportamiento propio de los procesos de aprendizaje por refuerzo en los que el agente se aproxima a un límite de rendimiento bajo las condiciones de entrenamiento establecidas.

La recompensa media del primer 20% de los episodios fue de 4,61 puntos, mientras que la del último 20% llegó a los 18,88 puntos, lo que representa una mejora de 14,27 puntos. Al mismo tiempo, la duración promedio de los episodios pasó de 65,2 pasos a 197,3 pasos, un incremento de 132,1 pasos, lo que muestra que el agente aprendió a mantener sus 3 vidas activas por más tiempo, por lo que pudo acumular una mayor recompensa.

B. Comparación PRE vs POST - Espacio de Estados

Con el fin de evaluar el impacto del aprendizaje sobre la estructura del espacio de estados explorado, se recolectaron 50.000 frames de un agente con política aleatoria, asignado al escenario PRE y 50.000 frames del agente PPO entrenado,

Fig. 2. Proyecciones PCA, t-SNE y UMAP del espacio de estados del agente aleatorio. Los 5000 frames obtenidos se colorean en naranja ante la presencia de recompensa y en azul en caso de ausencia

Fig. 3. Curvas de aprendizaje del agente PPO durante 1.000.000 pasos de entrenamiento. Al lado izquierdo se observa recompensa acumulada por episodio.

Y al lado derecho, la duración de los episodios en pasos. En ambos gráficos, la región sombreada representa los valores por episodio y la línea naranja la media móvil.

asignado al escenario POST. Cada escenario representa la proyección de ambos conjuntos al espacio bidimensional. Por otra parte, la recolección POST se elaboró con las tres vidas originales del juego.

Una vez evaluados ambos escenarios, se elaboró la Tabla III, donde se observa a proporción de frames con recompensa

aumentó de 4.31% a 9.50%, indicando que el agente entrenado encuentra espacio de estados con recompensa. Asimismo, la duración media de los episodios aumentó de 40.9 a 207.0 pasos, y la recompensa promedio se elevó de 1.76 a 19.66 puntos. Por último, la recompensa máxima pasó de 10 a 30 puntos, confirmando que el desempeño aumentó. La tabla III

Con el objetivo de complementar estos resultados de forma visual, ambos conjuntos de frames se proyectaron al espacio bidimensional mediante el flujo PCA-UMAP con reducción previa a 10 componentes principales y parámetros $n\text{ neighbors} = 15$ y $\text{min dist} = 0.1$. La Figura 4 ilustra ambos escenarios.

TABLE III

COMPARACIÓN DE MÉTRICAS PRE VS POST ENTRENAMIENTO

Métrica PRE (aleatorio) POST (PPO)

Estructura UMAP Dispersa y uniforme Compacta con clusters

Frames con recompensa 4.31% 9.50%

Duración episodios 40.9 pasos 207.0 pasos

Recompensa promedio 1.76 puntos 19.66 puntos

Recompensa máxima 10 puntos 30 puntos

Episodios completados 1223 241

Con base a la Figura 4, la proyección UMAP en el escenario PRE muestra una distribución dispersa y uniforme. Por un lado, los estados que generan recompensa se encuentran homogéneamente distribuidos junto a los estados que no la

generan. Además, se observa que hay un mayor número de estados que no generan recompensa. Por otro lado, la

Fig. 4. Comparación UMAP PRE vs POST entrenamiento con preprocesamiento PCA de 10 componentes. En la gráfica izquierda se ilustra el agente aleatorio,

los estados de recompensa, con color naranja, aparecen dispersos sin estructura identificable. Asimismo, a la derecha se ilustra el agente PPO tras 1.000.000

pasos, los estados con recompensa se concentran en una región central rodeada de estados sin recompensa en la periferia.

proyección UMAP del escenario POST exhibe un incremento drástico en los estados del agente que generaron recompensa.

C. Distribución de Acciones en Estados con Recompensa

En el escenario PRE, correspondiente a la política aleatoria, se observa que las cuatro acciones designadas al agente, aparecen distribuidas de forma aproximadamente uniforme en estados con recompensa, con frecuencias cercanas al 25% cada una. En contraste, en el escenario POST se ilustra la política aprendida por el agente, donde las únicas acciones que generaron recompensa fueron RIGHT y LEFT, resultado observado en la Figura 5